人工知能（AI）時代のサイバー脅威 vs AI による自律型サイバー防御

⚠ AI を悪用した新世代の脅威 (矛)

1. プロンプトインジェクション (Prompt Injection)
悪意ある指示文で AI の安全フィルターや制約を無効化し機密を奪う

2. ディープフェイク音声・動画詐欺 (Deepfake Phishing)
家族や CEO の声をわずか数秒のサンプルから精密再現し送金を指示

3. 学習データ汚染・ポイズニング (Data Poisoning)
学習データに微細な毒（バックドア）を混入させ、特定条件で誤認識を誘発

AI を活用した次世代の守護 (盾)

1. 自律型 SIEM・異常トラフィック即時検知
毎秒数百万行の通信ログをミリ秒単位で相関分析しゼロデイ攻撃を遮断

2. ディープフェイク生体・音声紋鑑識
微小な周波数歪みや血管脈波（rPPG）の非整合性を検知し偽造を判定

3. セキュア LLM ガードレール＆自動パッチ生成
ユーザー入出力を二重査定し、コード脆弱性の自動検証と修正提案を実行

人間の倫理と深い知性こそが、AI 技術を「世界を守る盾」として導く真の原動力